

Belegvariation

Ulf Hamster
Berlin-Brandenburgische Akademie der Wissenschaften

Inhalt

Problemanalyse

Lösungsansatz

Übungen mit Colab

Fallbeispiele (nächste Woche)

Problemanalyse

Beobachtung

- Suchtreffer weisen *Dubletten* auf
- ... beziehen sich auf die gleiche Lesart, Ereignis, linguistisches Konzept (*Semantik*)
- ... haben ähnlichen Satzbau (*Grammatik*)
- ... stammen aus/von denselben *Quellen* (Autor/innen, Werke, Zeiträume)

Ursachen

- Suchtreffer mit einem *gleich hohen Score* können sich auf die gleiche Menge von Bewertungsmerkmalen beziehen.
- Scoringmodelle bewerten einzelne Satzbelege *unabhängig voneinander*.

Beispiel: Dubletten für Suchbegriff “Regierungsauftrag”

Exakte *Dubletten*
in mehreren Zeitungsmanteln

Unterschiedliche *Quellen*
bevorzugen, ist nicht genug.

Andere Beispiele:

- Clickbait Repostings,
- Errata in Webartikeln,
- Neuauflage von Büchern
- Übernahme von Zitaten
- Retweets

- 1: Norddeutsche Neueste Nachrichten, 16.09.2022
Obwohl die Moderaten mit 19,1 Prozent weniger Stimmen erhielten als die Rechten, übernehmen sie den **Regierungsauftrag**.
- 2: Neue Osnabrücker Zeitung, 16.09.2022
Obwohl die Moderaten mit 19,1 Prozent weniger Stimmen erhielten als die Rechten, übernehmen sie den **Regierungsauftrag**.
- 3: Der Prignitzer, 16.09.2022
Obwohl die Moderaten mit 19,1 Prozent weniger Stimmen erhielten als die Rechten, übernehmen sie den **Regierungsauftrag**.
- 4: Schweriner Volkszeitung, 16.09.2022
Obwohl die Moderaten mit 19,1 Prozent weniger Stimmen erhielten als die Rechten, übernehmen sie den **Regierungsauftrag**.
- 5: Bote der Urschweiz, 09.09.2022
Seit 1955 - ihr erster Premier Winston Churchill war bereits im Amt - hat sie elf Männern und drei Frauen im Buckingham-Palast den **Regierungsauftrag** erteilt und damit ihre wichtigste konstitutionelle Aufgabe erfüllt . (sbo)
- 6: Luzerner Zeitung, 09.09.2022
Seit 1955 - ihr erster Premier Winston Churchill war bereits im Amt - hat sie elf Männern und drei Frauen im Buckingham-Palast den **Regierungsauftrag** erteilt und damit ihre wichtigste konstitutionelle Aufgabe erfüllt . (sbo)
- 7: St. Galler Tagblatt, 09.09.2022
Seit 1955 - ihr erster Premier Winston Churchill war bereits im Amt - hat sie elf Männern und drei Frauen im Buckingham-Palast den **Regierungsauftrag** erteilt und damit ihre wichtigste konstitutionelle Aufgabe erfüllt . (sbo)
- 8: Thurgauer Zeitung, 09.09.2022
Seit 1955 - ihr erster Premier Winston Churchill war bereits im Amt - hat sie elf Männern und drei Frauen im Buckingham-Palast den **Regierungsauftrag** erteilt und damit ihre wichtigste konstitutionelle Aufgabe erfüllt . (sbo)
- 9: Der Tagesspiegel, 09.09.2022
Seit 1955 - ihr erster Premier Winston Churchill war bereits im Amt - hatte sie elf Männern und drei Frauen stets im Buckingham-Palast den **Regierungsauftrag** erteilt.
- 10: Frankfurter Rundschau, 07.09.2022
Die nur von ihrer Partei gekürte britische Premierministerin holt sich in Balmoral ihren **Regierungsauftrag** ab / Von Sebastian Borger

Korpustreffer für »Regierungsauftrag«, aus dem Korpus DWDS-Zeitungskorpus (ab 1945) des Digitalen Wörterbuchs der deutschen Sprache, Zeitraum 2021-2022.

Lösungsansatz 1/2 – Das MECE-Prinzip

MECE = "mutually exclusive and collectively exhaustive" (Mengenlehre)

“mutually exclusive” bzw. disjunkt

- Die Menge aller ausgewählten Satzbelege solle keine bzw. *minimale Schnittmengen* hinsichtlich Bedeutungsähnlichkeit und grammatischer Ähnlichkeit, u.a. aufweisen.

“collectively exhaustive”

- Die *Vereinigungsmenge* aller ausgewählten Satzbelege sollte (idealerweise) das gesamte Bedeutungsspektrum umfassen

Lösungsansatz 2/2 – Quadratische Optimierung als Suchfilter

Zum Sortieren der Suchtreffer ermittle Gewichtungen w_i
durch Maximieren der Bewertungsgüte g_i
und Minimieren der aggregierten Ähnlichkeitsmetriken Q_{ij} zw. den Satzbelegen.

$$\begin{aligned} \min_{w_1, \dots, w_N} \quad & - \underbrace{\lambda \cdot \sum_{i=1}^N w_i g_i}_{\text{total goodness}} + (1 - \lambda) \underbrace{\sqrt{\sum_{i=1}^N \sum_{j=1}^N w_i Q_{i,j} w_j}}_{\text{total similarity}} \\ \text{s.t.} \quad & \sum_{i=1}^N w_i = 1 \\ & w_i \geq 0 \quad \forall i \\ & w_i \leq b \quad \forall i \end{aligned}$$
$$Q_{i,j} = \sum_k^M \beta_k D_{i,j}^{(k)} \quad \forall i, j$$

In der Software: **Nutzer/innen** können fünf **Präferenzparameter** per Slider-UI angeben:

1. Bewertungsgüte vs. Belegvariation (λ)
2. Semantische Ähnlichkeit 'abstrafen' (β_1)
3. Satzbau-Ähnlichkeit 'abstrafen' (β_2)
4. Dubletten 'abstrafen' (β_3)
5. Quellen-Ähnlichkeit 'abstrafen' (β_4)

Übungen mit Colab

Übung 1/4

Was bedeutet hier *semantische Ähnlichkeit*?

- Representationsvektoren je Satzbeleg werden mit SBert erzeugt (Contextual Sentence Embeddings) und
- die Cosinus-Ähnlichkeitsmetrik D_{ij} für ein Paar von Satzbelegen i und j berechnet.

Übung

- Semantische Ähnlichkeiten mit SBert berechnen
- https://colab.research.google.com/drive/1WjXf0g_ty2B_z_-uhMBtnJFVFxKdDhVn

Übung 2/4

Wie werden (Near)-Dubletten und ähnliche Quellenangaben erkannt?

- k-Shingling: Rohtext (inkl. Leerzeichen, Interpunktion) wird in jede mögliche Zeichenketten zerlegt bis max. Zeichenlänge k.
- Beispiel: “abcbab” mit $k=3 \Rightarrow \{a, ab, abc, b, bc, bca, c, ca, cab\}$
- Ein MinHash aus den Shingles erzeugen
- Berechne Jaccard-Ähnlichkeit zweier MinHashes

Übung

- Fingerprinting mit MinHash/LSH
- https://colab.research.google.com/drive/1_6UUOM7bGFqR1JPInCp5YWPP6WFM3Nb7?usp=sharing

Übungen 4/4

Quadratische Optimierung mit SBert-Ähnlichkeiten

https://drive.google.com/file/d/1clOkRIBmQ8hyv3Oo7FX1ueluzPSed_Xd/view?usp=sharing

Reverse Automatic Differentiation als Approximator für Quadratische Optimierungsprobleme

$$\begin{aligned}\mathcal{L} = & -\lambda \cdot \sum_{i=1}^N u_i g_i \\ & + (1 - \lambda) \cdot \sqrt{\sum_{i=1}^N \sum_{j=1}^N u_i Q_{i,j} u_j} \\ & + \alpha_1 \cdot \left(1 - \sum_{i=1}^N w_i\right)^2 \\ & + \alpha_2 \cdot \sum_{i=1}^N -\min(0, w_i) \\ & + \alpha_3 \cdot \sum_{i=1}^N -\min(0, b - w_i)\end{aligned}$$

$$v_i = w_i - \min(0, w) \quad \forall i$$

$$u_i = \frac{v_i}{\max(1e^8, \sum_{j=1}^N v_j)}$$

PyTorch und Tensorflow sind “Reverse Automatic Differentiation” Bibliotheken.

Wir müssen das Optimierungsproblem als Loss Function umschreiben.

Die Nebenbedingungen sind dann Regularization Penalties.

Quadratische Optimierung mit Tensorflow in Python

https://github.com/satzbeleg/keras-quadopt/blob/main/keras_quadopt/problem.py

Refactored Code in TFJS

<https://github.com/satzbeleg/evidence-app/blob/main/src/components/variation/quadopt.js>

Fallbeispiele

Käse 1/2 – Nur die Bewertungsgüte ($\lambda=100\%$)

Top-Suchtreffer:

v.a. Käse als Nahrungsmittel

Außer Brot und Wein wurden noch lange Öl (zur Taufe?), Käse, Oliven, Erstlingsfrüchte (S. 115 ed. Hauler; Klauser- Rech, RAC II, 500), Blumen u. a. »geopfert«, zum Unterhalt von Armen und Klerikern.

w₆: 0.0073 | Schweizer, E. u. a.: Abendmahl. In: Gallig, Kurt (Hg.), Die Religion in Geschichte und Gegenwart, Berlin: Directmedia Publ. 2000 [1957], S. 220

(Kaum) drei Käse hoch sein: (noch) ganz klein sein, spöttisch vor allem von einem kleinen Gernegroß gesagt, einem (Drei-)Käsehoch; schon 1767 im 'Versuch eines bremisch-niedersächsischen Wörterbuchs' (Band 2, S. 762):» Een Junge twe Kese hoog: ein kleiner kurzer Junge «; im niederdeutschen Raum machte man früher auf allen Höfen Käse nach Art der (Holländer)

w₇: 0.0073 | Röhrich, Lutz: Käse. In: Lexikon der sprichwörtlichen Redensarten [Elektronische Ressource], Berlin: Directmedia Publ. 2000 [1994], S. 27405

– Käse und Butter, Lapšin.

w₂: 0.0067 | Schlögel, Karl: Petersburg, München Wien: Carl Hanser Verlag 2002, S. 223

Dieser Erstlingskäse ist ein vollfetter Käse von erstklassigem Geschmack und hohem Nährwert.

w₃: 0.0067 | Die Landfrau, 24.01.1925

Die anderen, die vom Jungen beliefert worden waren, gaben uns einen Trostschluck und einen Happen Käse und neckten uns dafür.

w₄: 0.0067 | Alexander Granach, Da geht ein Mensch: Leck: btb Verlag 2007, S. 307

Käse 2/2 – Unterschiedliche Semantik ($\lambda=0\%$, $\beta_1=100\%$)

Käse in MWA

Die eiskalten Pole des Roten Planeten sind löchrig wie Schweizer Käse.

w_7 : 0.0135 | Michael Remke, *Erwischt!*, in: *Bild* 15.03.2000, S. 7

Käse als Nahrungsmittel

Der Therapeut drückt mit einer Hand auf den schulterhoch ausgestreckten Arm des Patienten, und der hält dabei gleichzeitig ein Stück Käse in seinem Mund.

w_{26} : 0.0134 | Jörg Zittlau, *Handauflegen soll verborgene Allergien aufspüren*, in: *DIE WELT* 16.02.2002, S. TV6

Eine Frau, die sich makrobiotisch ernährte, litt an Übelkeit, bis sie sich erlaubte, Käse zu essen.

w_{66} : 0.0134 | Wilberg, Gerlinde M.: *Zeit für uns*, München: Frauenbuchverl. 1979, S. 25

Die angewandten Tests reagierten auch auf Käse positiv; dies sei die einzig denkbare Erklärung für das Ergebnis.

w_6 : 0.0134 | o.A., *Etikettenschwindel bei Rindfleisch-Wurst*, in: *Süddeutsche Zeitung* 28.12.2000, S. M 2

Käse, abw. als Geschwätz

Auf den Käse haben sie mir noch nicht geantwortet.

w_{85} : 0.0133 | Brief von Ernst G. an Irene G. vom 26.01.1943, *Feldpost-Archive mkb-fp-0270*

digitalisieren 1/2 – Güte vs. Semantik & Grammatik ($\lambda=25\%$, $\beta_1=50\%$, $\beta_2=50\%$)

Viele Satzbelege
aus einer Quelle
(Die ZEIT)

Der Protest mit Massen-Mails sollte das Rathaus blockieren, in dem alle Entscheidungsprozesse digitalisiert sind.

w_{13} : 0.0184 | Die Zeit, 29.10.1998, Nr. 45

Die gemeinnützige Stiftung, deren 35-Millionen-Dollar-Haushalt von der amerikanischen Regierung mitfinanziert wird, digitalisiert und katalogisiert die Videobänder zu einer »digitalen Bibliothek«.

w_0 : 0.0184 | konkret, 1996

Wird Digital-Fernsehen vor allem mit Bezahlfernsehen identifiziert, so dürfte es schwer werden, das soeben von der Bundesregierung proklamierte Ziel zu erreichen und bis zum Jahr 2010 die Übertragungstechnik komplett zu digitalisieren.

w_7 : 0.0184 | Die Zeit, 03.09.1998, Nr. 37

Das Sterben wird also zügig digitalisiert, das Leben nach dem Tod nicht minder.

w_{24} : 0.0183 | Die Zeit, 03.05.1996, Nr. 19

Ähnlich wie bei der Aufnahme einer Compact Disc (CD) wird das analoge Sprachsignal zunächst digitalisiert.

w_{48} : 0.0183 | o.A., Der Computer, der aufs Wort gehorcht, in: Süddeutsche Zeitung 16.02.1995, S. 24

digitalisieren 2/2 – unterschiedl. Quellen ($\lambda=25\%$, $\beta_1=50\%$, $\beta_2=50\%$, $\beta_4=100\%$)

jetzt
ZEIT, C't, konkret,
unbekannt, Bild

Vor allem sollten wir nach den Menschen fragen, die darüber entscheiden, welche Information digitalisiert wird und welche nicht; ob uns in der Flut der Netzinformationen noch Zeit zur Erinnerung und Gedächtnis genug bleibt, uns an anderes zu erinnern als an die perfekte Beherrschung des Netzes und seiner Chancen.

w₃: 0.0188 | Die Zeit, 28.06.1996, Nr. 27

Dabei besteht das geringste Problem darin, alle Bilder zu digitalisieren.

w₄₅: 0.0185 | C't, 2000, Nr. 8

Die gemeinnützige Stiftung, deren 35-Millionen-Dollar-Haushalt von der amerikanischen Regierung mitfinanziert wird, digitalisiert und katalogisiert die Videobänder zu einer »digitalen Bibliothek«.

w₆: 0.0184 | konkret, 1996

Und was wäre, wenn man jedes der schätzungsweise 60 Millionen existierenden Bücher nur einmal digitalisieren würde?

w₅₉: 0.0183 | 37

Die weltberühmte Gutenbergbibel (aus dem Jahr 1456) gibt es jetzt digitalisiert.

w₂₁: 0.0183 | o.A., NEWS-Gute-Schlechte, in: Bild 23.03.2000, S. 4

blau 1/2 – Semantik ($\lambda=0\%$, $\beta_1=100\%$)

Farbe

Die Farbe der rohen Bohne ist grau, blau, grün oder gelb.

w₄₇: 0.0135 | Kölling, Alfred: Fachbuch für Kellner, Leipzig: Fachbuchverl. VEB 1962 [1956], S. 112

Die Farbe ist je nach Grund blau, weiß, gelb, gold, auch mit andersfarbigem Rand, Gold setzt sich durch.

w₄₈: 0.0134 | Schiller, G.: Nimbus. In: Die Religion in Geschichte und Gegenwart, Berlin: Directmedia Publ. 2000 [1960], S. 13604

Die hübsche Nina (22) träumt von einem Mann mit blauen Augen.

w₁₉: 0.0134 | o.A., 214 Hamburger Singles zum Verlieben, in: Bild 24.01.2006, S. 1

Es wurde mit einem Gitterspektrometer die Luftwellenlänge der zweiten Harmonischen im blauen Spektralbereich gemessen.

w₉₆: 0.0134 | Hollemann, Günter: Ein Dioden-gepumpter Nd:YAG Laser für ein Indium-Frequenznormal, Garching bei München: Max-Planck-Inst. für Quantenoptik 1993, S. 54

MWA

Doch diesmal kommt sie nicht mit einem blauen Auge davon.

w₃₂: 0.0133 | Jürgen Wenzel, Luxus-Luder fährt Amok auf'm Kudamm, in: Bild 16.08.2005, S. 5

blau 2/2 – Mehr Variation im Satzbau ($\lambda=0\%$, $\beta_1=50\%$, $\beta_2=50\%$)

Immer noch
in den Suchtreffern

Neue
Suchtreffer

Er lächelt, mit der blauen Mütze, seinem roten Halstuch.

w₉₇: 0.0135 | o. A.: Reportage vom Großen Preis von Deutschland auf dem Nürburgring, 17.07.1932

Die hübsche Nina (22) träumt von einem Mann mit blauen Augen.

w₁₉: 0.0135 | o.A., 214 Hamburger Singles zum Verlieben, in: Bild 24.01.2006, S. 1

Beim "Blauen Engel" war das natürlich überdimensional.

w₁₄₃: 0.0133 | Der Spiegel, 29.03.1993

Es wurde mit einem Gitterspektrometer die Luftwellenlänge der zweiten Harmonischen im blauen Spektralbereich gemessen.

w₉₆: 0.0133 | Hollemann, Günter: Ein Dioden-gepumpter Nd:YAG Laser für ein Indium-Frequenznormal, Garching bei München: Max-Planck-Inst. für Quantenoptik 1993, S. 54

Die physikalisch unterschiedlichen Umfeldler bewirken unterschiedliche Verschiebungen der Farbe der physikalisch identischen blauen Testfelder.

w₂₂: 0.0133 | Hoffmann, K.-P. u. Wehrhahn, Christian: Zentrale Sehsysteme. In: Dudel, Josef u. a. (Hgg.) Neurowissenschaft, Berlin: Springer 1996, S. 424

Quellen – Literatur

- [1] Kilgarriff, A., Husák, M., McAdam, K., Rundell, M., Rychlý, P., 2008. GDEX: Automatically Finding Good Dictionary Examples in a Corpus. Presented at the Proceedings of the 13th EURALEX International Congress, pp. 425–432.
- [2] Didakowski, J., Lemnitzer, L., Geyken, A., 2012. Automatic example sentence extraction for a contemporary German dictionary, in: Proceedings of the 15th EURALEX International Congress. Presented at the EURALEX 2012, Department of Linguistics and Scandinavian Studies, University of Oslo, Oslo, Norway, pp. 343–349.

Quellen – Software

Softwarerepositorien für das EVIDENCE-Projekt: <https://github.com/satzbeleg>

Quadratische Optimierung mit Keras: <https://github.com/satzbeleg/keras-quadopt>

Best-Worst-Scaling Rankings verarbeiten: <https://github.com/satzbeleg/bwsample>

Contextual Sentence Embeddings mit SBert:
<https://github.com/UKPLab/sentence-transformers>

Dependenzparsing mit trankit: <https://github.com/nlp-uoregon/trankit>

Bäume in Teilbäume zerlegen mit treesimi: <https://github.com/satzbeleg/treesimi>

MinHash/LSH mit Datasketch: <https://github.com/ekzhu/datasketch>

Strings shinglen: <https://github.com/ulf1/kshingle>